

**ANALISIS HYBRID RESAMPLING SMOTE-ENN UNTUK
PENANGANAN KETIDAKSEIMBANGAN KELAS PADA PREDIKSI
RISIKO PENYAKIT STROKE**



Dosen Pengampu:
Meida Cahyo Untoro, S.Kom., M.Kom.

Mata Kuliah:
Penambangan Data IF25-32025

Kelompok:
09

Disusun Oleh:

Muhammad Fadhilah Akbar	123140003
Annisa Al-Qoriah	123140030
Muhammad Romadhon Santoso	123140031
Sigit Kurnia Hartawan	123140033
Stevanus Cahya Anggara	123140038
Pradana Figo Ariasya	123140063

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2026**

DAFTAR ISI

DAFTAR ISI.....	1
BAB 1.....	3
PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Rumusan Masalah.....	4
1.3 Tujuan Penelitian.....	4
1.4 Batasan Masalah.....	5
BAB 2.....	6
TINJAUAN PUSTAKA.....	6
2.1 Data Mining dan Preprocessing.....	6
2.2 Imbalance Data.....	6
2.3 Metode yang Digunakan SMOTE DAN SMOTE-ENN.....	7
2.4 Matrik Evaluasi Model.....	9
2.5 Penelitian Terkait.....	10
BAB 3.....	11
METODOLOGI PENELITIAN.....	11
3.1 Alur Penelitian.....	11
3.2 Deskripsi Dataset.....	12
3.3 Prosedur Eksperimen.....	13
3.3.1 Pembagian Data.....	13
3.3.2 Metode Resampling Yang Digunakan.....	13
3.3.3 Algoritma Klasifikasi.....	14
3.3.4 Metrik Evaluasi.....	14
BAB 4.....	16
HASIL DAN PEMBAHASAN.....	16
4.1 Eksplorasi Data (EDA).....	16
4.1.1 Gambaran Umum Dataset.....	16
4.1.2 Distribusi Fitur.....	16
4.1.3 Distribusi Kelas Target.....	21
4.2 EDA Spesifik Topik.....	21
4.2.1 Hybrid Method.....	21
4.2.2 Loop Training & Evaluasi.....	22
4.2.3 Visualisasi Distribusi Kelas Setelah Resampling.....	22
4.3 Hasil Perbandingan Metode.....	24
4.3.1 Tabel Perbandingan Performa.....	24
4.3.2 Visualisasi Perbandingan.....	25
4.4 Pembahasan.....	26
BAB 5.....	27
KESIMPULAN DAN SARAN.....	27
5.1 Kesimpulan.....	27

5.2 Keterbatasan Penelitian.....	27
5.3 Saran.....	27
DAFTAR PUSTAKA.....	29
LAMPIRAN.....	31

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Penyakit stroke merupakan salah satu kondisi medis kritis yang menjadi penyebab utama kematian dan kecacatan permanen di seluruh dunia. Faktor risiko stroke sangat beragam, mulai dari usia, hipertensi, hingga anomali pada indeks massa tubuh atau BMI (Shiozawa et al., 2021). Keterlambatan penanganan pada pasien yang memiliki risiko tinggi dapat berakibat fatal. Oleh karena itu, seiring dengan kemajuan teknologi informasi medis, pendekatan *machine learning* semakin dimanfaatkan untuk memprediksi stroke sejak dini. Algoritma pembelajaran mesin mampu menganalisis pola rekam medis pasien untuk membantu tenaga medis dalam mengambil tindakan yang lebih cepat dan akurat (Thanka et al., 2025).

Meskipun *machine learning* menawarkan potensi besar dalam analisis prediksi medis, implementasinya kerap dihadapkan pada tantangan ketidakseimbangan kelas (*imbalanced data*). Pada kasus prediksi stroke, proporsi pasien yang benar-benar terdiagnosa positif stroke umumnya jauh lebih sedikit (kelas minoritas) dibandingkan pasien sehat (kelas mayoritas). Ketimpangan ekstrem ini menyebabkan model klasifikasi cenderung bias terhadap kelas mayoritas selama proses pelatihan. Akibatnya, model sering kali memunculkan tingkat *False Negative* yang tinggi, yakni kegagalan mendeteksi pasien yang sebenarnya berisiko stroke. Dalam konteks medis, kesalahan prediksi semacam ini sangat berbahaya karena dapat menghilangkan kesempatan penanganan dini pada pasien (Handayani & Taufiq, 2024).

Berbagai teknik *resampling* data telah dikembangkan untuk mengatasi permasalahan ini. Salah satu pendekatan *oversampling* yang paling umum digunakan adalah *Synthetic Minority Over-sampling Technique* (SMOTE), yang bekerja dengan cara mensintesis data buatan pada kelas minoritas sehingga distribusinya menjadi seimbang. Namun, penggunaan SMOTE secara tunggal memiliki kelemahan mendasar. Metode ini sering kali menghasilkan sampel sintesis di area perbatasan batas keputusan yang tumpang tindih (*overlapping*) dengan kelas mayoritas, sehingga justru menciptakan noise baru yang dapat menurunkan performa model secara keseluruhan (Putra et al., 2024).

Sebagai solusi atas keterbatasan tersebut, pendekatan hibrida SMOTE-ENN (*Synthetic Minority Over-sampling Technique dan Edited Nearest Neighbors*) diusulkan sebagai metode yang lebih tangguh. SMOTE-ENN menggabungkan keunggulan oversampling untuk menyeimbangkan data, sekaligus *undersampling* menggunakan ENN sebagai mekanisme pembersihan data (*data cleaning*). Setelah SMOTE menyeimbangkan proporsi antar kelas, ENN akan mengidentifikasi dan menghapus observasi dari kelas mayoritas maupun minoritas yang dianggap sebagai anomali atau noise di daerah perbatasan. Kombinasi ini secara signifikan mampu menghasilkan batas keputusan yang lebih bersih dan tegas antar kelas, sehingga performa klasifikasi dapat meningkat secara tajam, terutama dalam mengenali kelas minoritas yang krusial (Riantika et al., 2025).

Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk mengimplementasikan dan menguji efektivitas metode *hybrid* resampling SMOTE-ENN pada stroke prediction dataset. Evaluasi akan dilakukan untuk membuktikan sejauh mana kemampuan metode hibrida ini dalam mengatasi bias akibat *imbalanced* data, mengurangi noise, dan secara signifikan meningkatkan metrik evaluasi prediktif dalam klasifikasi risiko penyakit stroke.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana pengaruh data yang tidak seimbang (*imbalanced data*) terhadap kinerja model machine learning dalam memprediksi risiko penyakit stroke?
2. Bagaimana efektivitas penerapan metode *hybrid resampling* SMOTE-ENN dalam menyeimbangkan distribusi kelas sekaligus mengurangi noise pada stroke prediction dataset jika dibandingkan dengan penggunaan data asli tanpa resampling?
3. Apakah penggunaan SMOTE-ENN mampu meningkatkan performa model secara signifikan, khususnya pada kemampuan mendeteksi kelas minoritas (pasien berisiko stroke) yang dievaluasi menggunakan metrik *Recall*, *F1-Score*, dan AUC-ROC?

1.3 Tujuan Penelitian

Penelitian ini dilaksanakan untuk menyelesaikan permasalahan terkait penanganan ketidakseimbangan data pada prediksi risiko stroke. Secara spesifik tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Menganalisis dampak ketidakseimbangan kelas (*imbalanced data*) pada dataset rekam medis stroke terhadap tingkat bias model klasifikasi dan kemampuannya dalam memprediksi risiko penyakit stroke secara akurat.
2. Mengimplementasikan dan mengukur efektivitas teknik *hybrid resampling* SMOTE-ENN dalam menyeimbangkan proporsi kelas sekaligus membersihkan *noise (data cleaning)*, serta membandingkan hasilnya dengan penggunaan data asli tanpa proses resampling.
3. Membuktikan secara empiris bahwa penerapan SMOTE-ENN mampu memberikan peningkatan performa yang signifikan pada model pembelajaran mesin, terutama dalam mengenali pasien berisiko tinggi stroke (kelas minoritas) yang dievaluasi secara terukur menggunakan *Confusion* metrik, *Recall*, F1-Score, dan AUC-ROC.

1.4 Batasan Masalah

Ruang lingkup penelitian memerlukan batasan-batasan teknis yang spesifik agar tetap fokus dan terstruktur. Batasan masalah pada penelitian ini ditetapkan sebagai berikut:

1. Data yang digunakan bersumber dari *Healthcare Dataset Stroke Data* yang berisi informasi seperti usia, status hipertensi, kadar glukosa, indeks massa tubuh (BMI), dan status merokok pasien.
2. Ruang lingkup penelitian difokuskan pada tahap *preprocessing* data, khususnya penerapan metode SMOTE-ENN untuk menangani ketidakseimbangan kelas.
3. Evaluasi hasil klasifikasi akan lebih difokuskan pada metrik *Recall* dan *F1-Score*, karena penelitian ini memprioritaskan kemampuan model dalam mendeteksi kelas pasien stroke secara tepat tanpa mengabaikan *false negative*.

BAB 2

TINJAUAN PUSTAKA

2.1 *Data Mining dan Preprocessing*

Data Mining merupakan proses untuk mengenali pola, hubungan, serta informasi yang bermakna dari data dalam jumlah besar dengan memanfaatkan teknik statistik, matematis, dan komputasional. Dalam kerangka *Knowledge Discovery in Databases* (KDD), data mining merupakan bagian dari rangkaian proses yang meliputi seleksi data, *preprocessing*, *transformasi*, pemodelan, dan evaluasi hasil (Han et al., 2005). Hal ini menunjukkan bahwa keberhasilan analisis tidak hanya bergantung pada algoritma yang digunakan, tetapi juga pada kualitas data yang diproses.

Seiring berkembangnya penelitian terkini, *preprocessing* telah menjadi bagian yang paling menentukan dalam alur kerja *machine learning*. Mengingat data di lapangan sering kali tidak sempurna, seperti adanya *noise*, *missing value*, serta distribusi yang tidak seimbang sehingga dapat menurunkan performa model. Penelitian terbaru menunjukkan bahwa kualitas data memiliki pengaruh yang sangat signifikan terhadap hasil prediksi, bahkan seringkali lebih dominan dibandingkan pemilihan algoritma (Zhang et al., 2024). Oleh karena itu, proses *preprocessing* seperti pembersihan data penanganan ketidakseimbangan kelas menjadi pondasi utama dalam menciptakan model yang handal, khususnya pada sektor yang sensitif seperti bidang kesehatan.

2.2 *Imbalance Data*

Ketidakseimbangan kelas atau *Class Imbalance* merupakan kondisi di mana distribusi jumlah data antar kelas tidak seimbang, sehingga satu kelas (mayoritas) mendominasi dibandingkan kelas lainnya (minoritas). Fenomena ini banyak ditemukan pada berbagai bidang seperti deteksi *fraud*, diagnosis penyakit langka, dan sistem keamanan jaringan. Tingkat ketidakseimbangan biasanya diukur menggunakan *Imbalance Ratio* (IR), yaitu perbandingan jumlah data mayoritas terhadap minoritas. Dataset dengan IR tinggi (misalnya >10:1) menjadi tantangan besar bagi algoritma klasifikasi (He & Garcia, 2009).

Dampak utama dari kondisi ini adalah munculnya bias pada model, di mana algoritma cenderung mengoptimalkan akurasi keseluruhan tanpa memperhatikan performa pada kelas minoritas. Hal ini dikenal sebagai *accuracy paradox*, yaitu kondisi

dimana nilai akurasi tinggi tidak mencerminkan kemampuan model yang sebenarnya dalam mendeteksi kelas penting. Penelitian terbaru menunjukkan bahwa pada kasus medis, kegagalan mendeteksi kelas minoritas dapat berdampak signifikan terhadap hasil prediksi (Taskiran et al., 2025). Oleh karena itu, penggunaan metrik seperti F1-score dan AUC-ROC menjadi lebih relevan dibandingkan accuracy dalam mengevaluasi model pada data tidak seimbang.

2.3 Metode yang Digunakan SMOTE DAN SMOTE-ENN

Untuk mengatasi permasalahan imbalanced data, salah satu pendekatan yang banyak digunakan adalah teknik resampling. Metode ini bertujuan untuk menyeimbangkan distribusi data melalui proses oversampling pada kelas minoritas atau undersampling pada kelas mayoritas. Salah satu metode yang paling populer adalah *SMOTE* yang diperkenalkan oleh Chawla et al. (2002). *SMOTE* bekerja dengan menghasilkan data sintesis berdasarkan kedekatan antar sampel minoritas menggunakan pendekatan interpolasi. Secara matematis, proses pembentukan data sintesis pada *SMOTE* dapat dituliskan sebagai:

$$x_{new} = x_i + \lambda(x_{zi} - x_i)$$

di mana $\lambda \in [0,1]$ merupakan bilangan acak. Meskipun efektif dalam meningkatkan jumlah data minoritas, *SMOTE* memiliki kelemahan yaitu dapat menghasilkan data noise, terutama pada area *overlap* antar kelas.

Untuk mengatasi kelemahan tersebut, dikembangkan metode *hybrid* seperti *SMOTE-ENN* yang mengombinasikan proses *oversampling* dan *undersampling* dalam satu pendekatan terpadu. Metode *SMOTE-ENN* terdiri dari dua tahapan utama, yaitu *SMOTE* sebagai proses pembangkitan data sintesis dan *Edited Nearest Neighbor* (ENN) sebagai proses pembersihan data. Pada tahap kedua, ENN bekerja dengan mengevaluasi setiap sampel berdasarkan kedekatan dengan tetangga terdekatnya. Sampel yang tidak sesuai dengan mayoritas kelas dari *k-nearest neighbor* akan dihapus karena dianggap sebagai *noise* atau berada pada area ambigu. Pendekatan ini memungkinkan terbentuknya *decision boundary* yang lebih jelas dan representatif.

Pada tahap kedua, ENN bekerja dengan mengevaluasi setiap sampel berdasarkan kedekatan dengan tetangga terdekatnya. Sampel yang tidak sesuai dengan mayoritas kelas dari *k-nearest neighbor* akan dihapus karena dianggap sebagai noise atau berada pada

area ambigu. Pendekatan ini memungkinkan terbentuknya decision boundary yang lebih jelas dan representatif.

Untuk memberikan gambaran yang lebih jelas mengenai perbedaan metode yang digunakan, berikut disajikan perbandingan antara SMOTE dan SMOTE-ENN:

Perbandingan Metode Resampling

Metode	Mekanisme	Keunggulan	Kelemahan
SMOTE	Menghasilkan data sintetis pada kelas minoritas menggunakan interpolasi antar sampel terdekat	Meningkatkan jumlah data minoritas dan mengurangi ketidakseimbangan kelas	Berpotensi menghasilkan noise, terutama pada area overlap antar kelas
SMOTE-ENN	Kombinasi SMOTE (oversampling) dan ENN (undersampling), yaitu menghasilkan data sintetis kemudian menghapus data yang tidak konsisten dengan tetangga terdekat	Mampu menyeimbangkan data sekaligus membersihkan noise secara lebih efektif serta menghasilkan decision boundary yang lebih jelas	Dapat mengurangi jumlah data secara signifikan setelah proses ENN

Berdasarkan tabel di atas, metode SMOTE-ENN dipilih dalam penelitian ini karena tidak hanya mampu menyeimbangkan distribusi data, tetapi juga melakukan pembersihan noise secara lebih efektif dibandingkan SMOTE. Hal ini menjadikan SMOTE-ENN lebih sesuai untuk digunakan pada dataset dengan tingkat ketidakseimbangan yang tinggi, khususnya pada data kesehatan.

Penelitian terbaru menunjukkan bahwa metode hybrid seperti SMOTE-ENN mampu meningkatkan performa model klasifikasi secara signifikan, terutama dalam meningkatkan kemampuan model dalam mendeteksi kelas minoritas (Zhang et al., 2024; Taskiran et al., 2025). Oleh karena itu, metode ini dianggap relevan dan efektif untuk diterapkan dalam prediksi risiko penyakit stroke.

2.4 Matrik Evaluasi Model

Dalam penelitian klasifikasi, khususnya pada data yang tidak seimbang, diperlukan metrik evaluasi yang mampu menggambarkan performa model secara menyeluruh. Salah satu pendekatan yang digunakan adalah melalui *Confusion Matrix*, yang menyajikan hasil prediksi model ke dalam empat kategori, yaitu *True Positive (TP)*, *True Negative (TN)*, *False Positive (FP)*, dan *False Negative (FN)*. Berdasarkan matriks ini, berbagai metrik evaluasi dapat dihitung untuk menilai kinerja model secara lebih detail.

Recall atau *sensitivity* merupakan metrik yang mengukur kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya. *Recall* dihitung sebagai perbandingan antara jumlah *True Positive* terhadap total data positif, yaitu:

$$Recall = \frac{TP}{TP + FN}$$

Metrik ini sangat penting dalam konteks data kesehatan karena menunjukkan seberapa baik model dalam mengidentifikasi kasus yang benar-benar positif, seperti pasien yang berisiko mengalami stroke.

Selain itu, *F1-Score* digunakan sebagai metrik utama dalam *data imbalanced* karena merupakan rata-rata harmonis dari *precision* dan *recall*, yang dirumuskan sebagai:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

F1-Score memberikan keseimbangan antara ketepatan dan kelengkapan prediksi, sehingga lebih representatif dalam mengevaluasi performa model pada data yang tidak seimbang.

Di sisi lain, AUC-ROC (*Area Under Curve - Receiver Operating Characteristic*) digunakan untuk mengukur kemampuan model dalam membedakan antara kelas positif dan negatif secara keseluruhan. Nilai AUC yang mendekati 1 menunjukkan bahwa model memiliki kemampuan diskriminasi yang baik. Penelitian terbaru menegaskan bahwa metrik seperti *F1-score* dan AUC-ROC lebih mampu merepresentasikan performa model dibandingkan *accuracy* dalam kondisi data tidak seimbang (Taskiran et al., 2025).

2.5 Penelitian Terkait

Penelitian mengenai penanganan imbalanced data terus berkembang dalam beberapa tahun terakhir. Zhang et al. (2024) mengusulkan pengembangan metode *SMOTE* yang mampu mengurangi *noise* pada data sintetis sehingga meningkatkan performa klasifikasi. Selain itu, Taskiran et al. (2025) menunjukkan bahwa metode *hybrid* seperti SMOTE-ENN memberikan hasil yang lebih stabil dan akurat dibandingkan metode oversampling konvensional.

Dalam domain kesehatan, penelitian terbaru menunjukkan bahwa penerapan metode resampling, khususnya SMOTE-ENN, mampu meningkatkan performa model dalam mendeteksi penyakit dengan distribusi data yang tidak seimbang. Hal ini menunjukkan bahwa teknik *hybrid* tidak hanya menyeimbangkan data, tetapi juga meningkatkan kualitas pembelajaran model secara keseluruhan.

Perbedaan penelitian ini dengan penelitian sebelumnya terletak pada fokus analisis terhadap penerapan SMOTE-ENN dalam prediksi risiko penyakit stroke serta evaluasi komprehensif menggunakan berbagai metrik performa. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi dalam memahami efektivitas metode *hybrid* dalam meningkatkan performa model pada data kesehatan.

BAB 3

METODOLOGI PENELITIAN

3.1 Alur Penelitian.

Metodologi penelitian ini dilakukan melalui beberapa tahapan yang disusun secara sistematis agar penelitian dapat berjalan dengan baik dan terstruktur. Tahapan penelitian dimulai dari pengumpulan data, preprocessing data, penerapan metode, pemodelan menggunakan algoritma machine learning, hingga evaluasi model.

Secara umum, alur penelitian dapat dilihat sebagai berikut :

Alur pipeline yang WAJIB diikuti:



1. Pengumpulan Data : Tahapan awal adalah tahapan pengumpulan dataset yang relevan dengan tujuan penelitian.
2. Eksplorasi (EDA) : Tahapan Eksplorasi adalah tahapan memahami isi data seperti melihat distribusi, pengecekan missing value , outlier, dan pola hubungan antar fitur.
3. Train-Test Split : Tahapan Train-Test Split adalah tahapan membagi dataset menjadi data latih (train) dan data uji (test).
4. Preprocessing (Train) : Tahapan Preprocessing adalah tahapan proses pembersihan dan transformasi data latih seperti handling missing value, encoding data kategorikal, normalisasi/standarisasi, dan balancing data.
5. Training : Tahapan Training Model adalah tahapan membangun model machine learning menggunakan data latih.
6. Evaluasi : Tahapan Evaluasi adalah tahapan model uji menggunakan data test untuk mengukur performa dengan metrik.
7. Analisis Hasil : Tahapan analisis hasil adalah tahapan interpretasi hasil evaluasi, membandingkan performa model, dan menarik kesimpulan.

3.2 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah Stroke Prediction Dataset yang diperoleh dari Kaggle

(<https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>) . Dataset ini terdiri dari :

- Jumlah sampel : 5.110 baris
- Jumlah fitur : 12 kolom (4 numerik, 5 kategorikal, 3 biner)
- Variabel target : stroke — [0 = tidak stroke, 1 = stroke]
- Distribusi kelas : Kelas 0 = 4.861 (95,13%), Kelas 1 = 249 (4,87%)
- Imbalance Ratio : 19,52 : 1 (Sangat Tidak Seimbang)
- Missing Values : Ada, fitur BMI (Body Max Index) memiliki 3,93% (201) missing values

NO	NAMA FITUR	TIPE	DESKRIPSI	MISSING %
1	ID	NUMERIK	Penanda unik setiap individu	0%
2	GENDER	KATEGORIKAL	Jenis kelamin individu (laki-laki atau perempuan)	0%
3	AGE	NUMERIK	Usia Individu	0%
4	HYPERTENSION	BINER	Status individu memiliki riwayat hipertensi atau tidak (0=tidak, 1=ya)	0%
5	HEART DISEASE	BINER	Status apakah individu memiliki riwayat penyakit jantung atau tidak (0=tidak, 1=ya)	0%
6	EVER_MARRIED	KATEGORIKAL	Status apakah individu pernah menikah atau belum (0=pernah, 1=belum pernah)	0%
7	WORK_TYPE	KATEGORIKAL	Jenis pekerjaan individu	0%
8	RESIDENCE_TYPE	KATEGORIKAL	Tempat tinggal individu (Urban=perkotaan, rural=pedesaan)	0%
9	AVG_GLUCOSE_LEVEL	NUMERIK	Rata-rata kadar glukosa dalam darah individu	0%

10	BMI	NUMERIK	Indeks massa tubuh individu menunjukkan kategori berat badan berdasarkan tinggi dan berat badan	3.93%
11	SMOKING_STATUS	KATEGORIKAL	Status kebiasaan merokok individu	0%
12	STROKE	BINER	Label apakah individu mengalami stroke atau tidak (0=tidak, 1=ya)	0%

3.3 Prosedur Eksperimen

3.3.1 Pembagian Data

Data dibagi menjadi training set (80%) dan test set (20%) menggunakan stratified sampling untuk menjaga proporsi kelas target. Pembagian dilakukan SEBELUM preprocessing apapun untuk menghindari data leakage (Kaufman et al., 2012).

```
# SPLIT DATASET 80% DATA TRAIN 20% DATA TEST
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
print(f"Training: {X_train.shape[0]} sampel | Test: {X_test.shape[0]} sampel")
```

3.3.2 Metode Resampling Yang Digunakan

Dalam penelitian ini, digunakan 3 metode resampling yang dibandingkan:

1. SMOTE (Synthetic Minority Over-sampling Technique) — Bekerja dengan cara memilih sampel minoritas, mencari k tetangga terdekat (k-nearest neighbors) dari kelas yang sama, kemudian membuat sampel sintesis baru melalui interpolasi linear pada segmen garis yang menghubungkan sampel asli dengan tetangganya. Secara matematis, sampel baru dihasilkan melalui rumus $x_{\text{new}} = x_i + \mu\lambda \times (x_{nn} - x_i)$, di mana $\lambda \in [0,1]$ adalah bilangan acak. Parameter: `sampling_strategy='auto'`, `k_neighbors=5`, `random_state=42`. Dipilih karena Digunakan sebagai standar oversampling untuk meningkatkan representasi kelas minoritas (pasien stroke) agar model tidak bias terhadap kelas mayoritas.
2. SMOTE-ENN (SMOTE + Edited Nearest Neighbours) — Merupakan metode hybrid yang menggabungkan proses oversampling SMOTE dengan proses pembersihan data menggunakan Edited Nearest Neighbours (ENN). Setelah sampel sintesis dibangkitkan, ENN akan menghapus sampel (baik mayoritas maupun minoritas) yang diklasifikasikan secara salah oleh tetangga terdekatnya

(misclassified by k-NN). Parameter: `sampling_strategy='auto'`, `random_state=42`. Dipilih karena kemampuannya dalam melakukan pembersihan data secara agresif, yang sangat efektif untuk mempertajam batas keputusan (decision boundary) pada dataset medis yang memiliki tingkat tumpang tindih (overlap) tinggi antar kelas .

3. Baseline — Model tanpa resampling sebagai pembanding. Model klasifikasi Random Forest yang dilatih menggunakan data asli tanpa melalui proses preprocessing penyeimbangan kelas (resampling). Berperan sebagai pembanding utama untuk mengukur sejauh mana peningkatan performa metrik (seperti F1-Score dan Recall) yang dihasilkan setelah penerapan teknik hybrid resampling.

Semua metode diterapkan HANYA pada training set. Evaluasi dilakukan pada test set asli yang tidak mengalami preprocessing resampling.

3.3.3 Algoritma Klasifikasi

Algoritma klasifikasi yang digunakan adalah Random Forest Classifier (Breiman, 2001) dengan parameter default dari scikit-learn (`n_estimators=100`, `random_state=42`) . Random Forest dipilih karena memiliki ketahanan (robustness) yang tinggi terhadap overfitting melalui mekanisme penggabungan hasil dari banyak pohon keputusan secara independen. Selain itu, algoritma ini tidak mewajibkan adanya proses feature scaling dan mampu menangani hubungan antar-fitur yang bersifat non-linear secara efektif, sehingga sangat fleksibel dan kuat dalam memproses berbagai karakteristik fitur pada dataset kesehatan yang digunakan.

3.3.4 Metrik Evaluasi

Metrik evaluasi yang digunakan meliputi:

- Recall (macro): Rata-rata recall per kelas — penting untuk mendeteksi kelas minoritas.
- F1-Score (macro): Harmonic mean dari precision dan recall — metrik utama perbandingan.
- AUC-ROC: Kemampuan model membedakan antar kelas.
- Confusion Matrix : Matriks yang memvisualisasikan distribusi hasil prediksi melalui nilai True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN) untuk memberikan gambaran detail mengenai kesalahan klasifikasi model.

Metrik utama yang digunakan untuk menentukan metode terbaik adalah F1-Score karena Hal ini dikarenakan F1-Score mampu menyeimbangkan nilai precision dan recall secara adil, sehingga memberikan informasi performa yang jauh lebih akurat dan informatif dibandingkan akurasi pada kondisi data yang sangat tidak seimbang (imbalanced) .

BAB 4

HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data (EDA)

4.1.1 Gambaran Umum Dataset


Dataset Stroke Prediction Dataset terdiri dari 5110 sampel dengan 12 fitur. Berdasarkan statistik deskriptif pada Tabel healthcare-dataset-stroke-data.csv , fitur age memiliki rentang nilai 0.08 hingga 82.0 dengan rata-rata 43.23 dan standar deviasi 22.61. Terdapat 201 missing value pada dataset ini, yang seluruhnya terkonsentrasi pada kolom bmi. Temuan penting lain dari statistik deskriptif menunjukkan adanya ketidakseimbangan kelas (class imbalance) yang signifikan pada variabel target (stroke), di mana hanya sekitar 4.87% (249 sampel) dari total data yang merupakan kasus positif stroke, sedangkan 95.13% lainnya adalah kasus negatif. Selain itu, fitur avg_glucose_level menunjukkan variansi yang cukup tinggi dengan nilai maksimum mencapai 271.74, jauh di atas nilai rata-ratanya (106.15), yang mengindikasikan adanya potensi outlier yang perlu ditangani pada tahap preprocessing. Fitur id juga teridentifikasi sebagai identitas unik yang tidak memiliki nilai prediktif sehingga harus dihapus sebelum proses pelatihan model.

```
df = pd.read_csv('healthcare-dataset-stroke-data.csv')
print(f"Dataset terdiri dari {df.shape[0]} baris dan {df.shape[1]} kolom")
print(f"\nStatistik Deskriptif:")
df.describe()
```


4.1.2 Distribusi Fitur



```
# Distribusi fitur numerik
num_cols = df.select_dtypes(include=[np.number]).columns
fig, axes = plt.subplots(2, 3, figsize=(16, 10))
axes = axes.flatten()
for i, col in enumerate(num_cols[:6]):
    axes[i].hist(df[col].dropna(), bins=30, alpha=0.7, color='steelblue', edgecolor='white')
    axes[i].set_title(f'{col} (skew={df[col].skew():.2f})', fontweight='bold')
    axes[i].set_ylabel('Frekuensi')
for j in range(min(6, len(num_cols)), 6):
    axes[j].set_visible(False)
plt.suptitle('Gambar 1. Distribusi Fitur Numerik', fontsize=13, fontweight='bold')
plt.tight_layout()
plt.show()
```



Distribusi Fitur Numerik





Distribusi work_type










4.1.3 Distribusi Kelas Target

```
target_col = '[nama_kolom_target]'\n\nclass_counts = df[target_col].value_counts()\n\ nir = class_counts.max() / class_counts.min()\n\nfig, axes = plt.subplots(1, 2, figsize=(12, 5))\n\nclass_counts.plot(kind='bar', ax=axes[0], color=['steelblue', 'coral'], edgecolor='white')\n\naxes[0].set_title(f'Distribusi Kelas (IR = {nir:.2f})', fontweight='bold')\n\naxes[0].set_ylabel('Jumlah Sampel')\n\nfor i, v in enumerate(class_counts):\n    axes[0].text(i, v + 5, f'{v}\\n({v/len(df)*100:.1f}%)', ha='center', fontweight='bold')\n\naxes[1].pie(class_counts, labels=class_counts.index, autopct='%1.1f%', colors=['steelblue', 'coral'])\n\naxes[1].set_title('Proporsi Kelas', fontweight='bold')\n\nplt.suptitle('Gambar 2. Distribusi Kelas Target', fontweight='bold')\n\nplt.tight_layout()\n\nplt.show()
```



4.2 EDA Spesifik Topik

4.2.1 Hybrid Method


```
from imblearn.combine import SMOTEENN\nfrom imblearn.over_sampling import SMOTE\n\nmethods = {\n    'Baseline': None,\n    'SMOTE Only': SMOTE(random_state=42),\n    'SMOTEENN': SMOTEENN(random_state=42)\n}
```

4.2.2 Loop Training & Evaluasi

```
all_results = []
for name, sampler in methods.items():
    if sampler is None:
        X_tr, y_tr = X_train_sc, y_train
    else:
        X_tr, y_tr = sampler.fit_resample(X_train_sc, y_train)
    print(f"{name}: {pd.Series(y_tr).value_counts().to_dict()}")
    model = RandomForestClassifier(random_state=42)
    model.fit(X_tr, y_tr)
    result, _ = evaluate_model(model, X_test_sc, y_test, name) # Test ASLI
    all_results.append(result)
df_compare = compare_methods(all_results)
```

4.2.3 Visualisasi Distribusi Kelas Setelah Resampling

```
# Distribusi kelas sebelum dan sesudah resampling
fig, axes = plt.subplots(1, len(methods), figsize=(5*len(methods), 4))
if len(methods) == 1: axes = [axes]
for ax, (name, sampler) in zip(axes, methods.items()):
    if sampler is None:
        y_plot = y_train
    else:
        _, y_plot = sampler.fit_resample(X_train_sc, y_train)
    counts = pd.Series(y_plot).value_counts().sort_index()
    counts.plot(kind='bar', ax=ax, color=['steelblue', 'coral'], edgecolor='white')
    ax.set_title(f'{name}\n(n={len(y_plot)})', fontweight='bold', fontsize=9)
    ax.set_ylabel('Jumlah')
    for i, v in enumerate(counts):
        ax.text(i, v + 5, str(v), ha='center', fontsize=8, fontweight='bold')
plt.suptitle('Gambar [N]. Distribusi Kelas per Metode Resampling', fontweight='bold')
plt.tight_layout()
plt.show()
```



Metode resampling menunjukkan perbedaan yang signifikan dalam distribusi kelas setelah proses penyeimbangan data. Pada kondisi awal (baseline), distribusi data terlihat sangat tidak seimbang, di mana jumlah kelas mayoritas jauh lebih besar dibandingkan kelas minoritas. Setelah diterapkan metode SMOTE, jumlah sampel pada kelas minoritas meningkat hingga mendekati atau sama dengan kelas mayoritas, sehingga distribusi data menjadi seimbang. Hal ini menunjukkan bahwa SMOTE efektif dalam mengatasi ketidakseimbangan data melalui proses oversampling.

Namun, pada metode SMOTE-ENN, jumlah total sampel yang dihasilkan cenderung lebih sedikit dibandingkan SMOTE. Hal ini disebabkan oleh proses cleaning menggunakan Edited Nearest Neighbor (ENN) yang menghapus sampel yang tidak konsisten dengan tetangga terdekatnya. Proses ini bersifat lebih agresif karena tidak hanya menghapus noise, tetapi juga sampel yang berada pada area overlap antar kelas. Akibatnya, meskipun distribusi data tetap relatif seimbang, jumlah data berkurang dibandingkan hasil SMOTE.

Perbedaan tingkat agresivitas dalam proses cleaning ini berpengaruh terhadap kualitas model yang dihasilkan. SMOTE cenderung mempertahankan lebih banyak data namun berpotensi menyisakan noise, sedangkan SMOTE-ENN menghasilkan data yang lebih bersih dengan decision boundary yang lebih jelas. Oleh karena itu, SMOTE-ENN berpotensi memberikan performa klasifikasi yang lebih baik, terutama dalam meningkatkan kemampuan model dalam mendeteksi kelas minoritas.

4.3 Hasil Perbandingan Metode

4.3.1 Tabel Perbandingan Performa

```
def evaluate_model(model, X_test, y_test, model_name="Model"):
    """Evaluasi lengkap satu model – gunakan untuk setiap metode."""
    y_pred = model.predict(X_test)
    try:
        y_proba = model.predict_proba(X_test)[: , 1]
        auc = roc_auc_score(y_test, y_proba)
    except:
        auc = None
    return {
        'Model': model_name,
        'Accuracy': accuracy_score(y_test, y_pred),
        'Precision': precision_score(y_test, y_pred, average='macro'),
        'Recall': recall_score(y_test, y_pred, average='macro'),
        'F1-Score': f1_score(y_test, y_pred, average='macro'),
        'AUC-ROC': auc
    }, y_pred

def compare_methods(results_list):
    """Buat tabel perbandingan."""
    return pd.DataFrame(results_list).round(4)
```

Tabel Perbandingan:

	Metode	Accuracy	Precision	Recall	F1-Score	ROC-AUC
0	Baseline	0.938356	0.000000	0.000000	0.000000	0.810106
1	SMOTE	0.916830	0.189189	0.112903	0.141414	0.808812
2	SMOTE-ENN	0.857143	0.176923	0.370968	0.239583	0.812962

Berdasarkan Tabel diatas, metode SMOTE-ENN menghasilkan F1-Score tertinggi sebesar 0.239, diikuti oleh SMOTE (0.141) dan Baseline (0.000). Baseline tanpa preprocessing hanya memperoleh F1-Score 0.000, menunjukkan peningkatan sebesar 23% setelah penerapan SMOTE-ENN.


Metode SMOTE-ENN mengungguli metode lainnya karena efektivitas mekanisme hibridanya. Penggunaan SMOTE secara tunggal sering kali menciptakan sampel buatan yang tumpang tindih (overlapping) di area perbatasan antar kelas, sehingga membingungkan model. Dengan tambahan algoritma Edited Nearest Neighbors (ENN), sampel-sampel noise yang tumpang tindih di area perbatasan tersebut diidentifikasi dan dihapus (data cleaning). Hasilnya batas keputusan pemisah antar kelas menjadi jauh lebih bersih dan tegas, sehingga model dapat melakukan klasifikasi dengan lebih sensitif dan akurat.

4.3.2 Visualisasi Perbandingan

```
# Bar Chart Semua Metrik
metrics = ['Accuracy', 'Precision', 'Recall', 'F1-Score']
x = np.arange(len(metrics))
width = 0.2
fig, ax = plt.subplots(figsize=(12, 6))
for i, (_, row) in enumerate(df_compare.iterrows()):
    ax.bar(x + i*width, [row[m] for m in metrics], width, label=row['Model'])
ax.set_xticks(x + width * (len(df_compare)-1) / 2)
ax.set_xticklabels(metrics)
ax.set_ylabel('Score'); ax.set_ylim(0, 1.05)
ax.set_title('Gambar [N]. Perbandingan Performa Metode [Topik]', fontweight='bold')
ax.legend(loc='lower right'); ax.grid(axis='y', alpha=0.3)
plt.tight_layout(); plt.show()

# ROC Curve (untuk Imbalanced & Missing Value)
fig, ax = plt.subplots(figsize=(8, 6))
for name, model in models_dict.items():
    RocCurveDisplay.from_estimator(model, X_test_sc, y_test, ax=ax, name=name, alpha=0.8)
ax.plot([0, 1], [0, 1], 'k--', label='Random')
ax.set_title('Gambar [N]. ROC Curve Perbandingan Metode', fontweight='bold')
ax.legend(loc='lower right'); plt.tight_layout(); plt.show()

# Confusion Matrix - Semua Metode
fig, axes = plt.subplots(1, len(models_dict), figsize=(5*len(models_dict), 4))
if len(models_dict) == 1: axes = [axes]
for i, (name, mdl) in enumerate(models_dict.items()):
    ConfusionMatrixDisplay.from_estimator(mdl, X_test_sc, y_test, ax=axes[i], cmap='Blues', colorbar=False)
    axes[i].set_title(f'{name}', fontweight='bold', fontsize=10)
plt.suptitle('Gambar [N]. Confusion Matrix per Metode', fontweight='bold')
plt.tight_layout(); plt.show()
```



4.4 Pembahasan

Metode Terbaik : SMOTE-ENN menghasilkan F1-Score terbaik (0,2396) karena efektivitas mekanisme hibridanya yang menggabungkan peningkatan jumlah sampel dengan pembersihan data. Berbeda dengan metode tunggal, SMOTE-ENN tidak hanya membangkitkan sampel sintetis untuk menyeimbangkan kelas, tetapi juga menggunakan Edited Nearest Neighbors (ENN) untuk menghapus sampel noise yang tumpang tindih di area perbatasan (overlap). Proses ini menghasilkan decision boundary yang lebih bersih dan tegas, sehingga model Random Forest dapat lebih sensitif dalam mendeteksi pasien berisiko stroke (kelas minoritas) tanpa terganggu oleh ambiguitas data di area perbatasan.

Kelemahan Metode Lain : Penggunaan SMOTE standar tanpa proses cleaning memiliki kelemahan mendasar karena menginterpolasi seluruh sampel minoritas secara membabi buta, termasuk yang berada jauh dari pusat kelas. Hal ini menyebabkan terciptanya sampel sintetis di area yang sudah didominasi kelas mayoritas, yang justru menambah noise dan mengaburkan batas keputusan model. Akibatnya, meskipun SMOTE berhasil meningkatkan nilai Recall dibandingkan baseline, nilai Precision tetap rendah karena banyaknya kesalahan klasifikasi pada area overlap tersebut.

Trade-off : Ditemukan trade-off yang signifikan pada penggunaan SMOTE-ENN terkait dengan agresivitas pembersihan datanya. Meskipun menghasilkan performa metrik yang lebih stabil, mekanisme ENN bersifat cukup agresif sehingga tidak hanya menghapus noise, tetapi juga berpotensi menghilangkan sebagian sampel minoritas asli yang berada di area overlap. Hal ini terlihat dari jumlah total sampel pada SMOTE-ENN yang lebih sedikit dibandingkan SMOTE standar. Namun, dalam konteks medis ini, peningkatan kualitas data dan kejelasan batas keputusan terbukti lebih krusial bagi performa model daripada sekadar mempertahankan kuantitas data yang tinggi namun kotor.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penerapan metode hybrid resampling SMOTE-ENN dalam mengatasi masalah Ketidakseimbangan kelas pada dataset rekam medis terbukti menurunkan kemampuan model machine learning secara drastis dalam mendeteksi kelas minoritas. Pengujian pada model Baseline tanpa tahap resampling menghasilkan nilai Recall dan F1-Score sebesar 0.000, yang menandakan bahwa model mengalami bias ekstrim terhadap kelas mayoritas dan sama sekali gagal mengenali pasien berisiko stroke. Penerapan metode hybrid resampling SMOTE-ENN secara efektif mampu menyeimbangkan distribusi kelas sekaligus memperbaiki kualitas batas keputusan (decision boundary). Mekanisme penggabungan oversampling dari SMOTE dan pembersihan data menggunakan ENN berhasil mengidentifikasi dan menghapus sampel-sampel noise yang saling tumpang tindih di area perbatasan antar kelas. Metode SMOTE-ENN terbukti memberikan peningkatan performa yang paling signifikan dibandingkan model Baseline maupun metode SMOTE tunggal. Evaluasi metrik menunjukkan bahwa SMOTE-ENN berhasil meningkatkan nilai F1-Score menjadi 0.239 dan Recall menjadi 0.370, sehingga model memiliki tingkat sensitivitas yang jauh lebih baik dalam mendeteksi kasus positif penyakit stroke.

5.2 Keterbatasan Penelitian

Beberapa keterbatasan yang ada dalam proses interpretasi hasil adalah pengujian model klasifikasi hanya dibatasi pada algoritma Random Forest dengan parameter bawaan, sehingga potensi performa maksimal dari model belum sepenuhnya tergali melalui proses optimasi hyperparameter. Evaluasi efektivitas metode resampling juga hanya difokuskan pada satu dataset spesifik, yaitu Healthcare Dataset Stroke Data, yang membatasi jangkauan generalisasi kesimpulan pada karakteristik dataset medis lainnya. Penanganan data kosong (*missing value*) pada fitur *Body Mass Index* (BMI) belum menerapkan teknik imputasi tingkat lanjut yang berpotensi mempengaruhi tingkat representasi data secara keseluruhan sebelum tahap resampling dilakukan.

5.3 Saran

Berbagai keterbatasan penelitian akan menjadi peluang bagi pengembangan penelitian selanjutnya. Eksplorasi menggunakan algoritma klasifikasi tingkat lanjut seperti XGBoost, LightGBM, atau algoritma berbasis *Deep Learning* perlu dilakukan untuk melihat potensi peningkatan performa deteksi pada data hasil SMOTE-ENN. Proses optimasi hyperparameter (*hyperparameter tuning*) baik pada algoritma klasifikasi maupun pada pengaturan resampling, seperti penyesuaian rasio sampel atau parameter tetangga terdekat. Pendekatan imputasi missing value yang lebih adaptif pada fitur-fitur medis klinis juga dapat dievaluasi untuk memastikan kualitas data awal menjadi lebih baik sebelum memasuki tahap penyeimbangan kelas.

DAFTAR PUSTAKA

- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Gunadi, I. G. A., Rahmawati, D. O., Risha, N., & Ardiayansah, D. (2025). Evaluation of the performance of the Smote, Smote Enn, and Borderline Smote resampling methods based on the number of outlier data with Z Score. *Lontar Komputer: Jurnal Ilmiah Teknologi Informasi*, 16(2), 101–112. <https://doi.org/10.24843/LKJITI.2025.v16.i02.p05>
- Han, H., Wang, W. Y., & Mao, B. H. (2005). Borderline-SMOTE: A new over-sampling method. *International Conference on Intelligent Computing (ICIC 2005)*, LNCS 3644, 878–887.
- Handayani, F., & Taufiq, R. M. (2024). Komparasi algoritma menggunakan teknik SMOTE dalam melakukan klasifikasi penyakit stroke otak. *Jurnal CoSciTech (Computer Science and Information Technology)*, 5(2), 367–372. <https://doi.org/10.37859/coscitech.v5i2.7439>
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox. *Journal of Machine Learning Research*, 18(17), 1–5.
- Putra, A., et al. (2024). Improving stroke detection with hybrid sampling and cascade generalization. *JUITA: Jurnal Informatika*, 12(1), 12–20. <https://doi.org/10.30595/juita.v12i1.19386>
- Riantika, I., Sartono, B., & Notodiputro, K. A. (2025). A hybrid sampling approach for handling data imbalance in ensemble learning algorithms. *Scientific Journal of Informatics*, 12(2), 249–258. <https://doi.org/10.15294/sji.v12i2.19163>
- Shiozawa, M., et al. (2021). Association of body mass index with ischemic and hemorrhagic stroke. *Nutrients*, 13(7), 1–13. <https://doi.org/10.3390/nu13072343>
- Siagian, N. A., Sipayung, S. P., Rikki, A., & Marbun, N. (2025). Integrating SMOTE with XGBoost for Robust Classification on Imbalanced Datasets: A Dual-Domain Evaluation. *Sinkron: Jurnal dan Penelitian Teknik Informatika*, 9(3), 2137–2147. <https://doi.org/10.33395/sinkron.v9i3.15029>
- Taskiran, S. F., Turkoglu, B., Kaya, E., & Asuroglu, T. (2025). A comprehensive evaluation of oversampling techniques for enhancing text classification performance. *Scientific Reports*, 15, Artikel 21631. <https://doi.org/10.1038/s41598-025-05791-7>
- Thanka, M. R., et al. (2025). Analyzing risk factors and handling imbalanced data for predicting stroke risk using machine learning. *International Journal of Advances in Intelligent Informatics*, 11(1), 39–54. <https://doi.org/10.26555/ijain.v11i1.1678>

- Tursina, D., Anggraeni, S. R., Fatichah, C., & Subakti, M. M. I. (2024). Metode Hibrida Oversampling untuk Menangani Imbalanced Multi-Label. *JUTI: Jurnal Ilmiah Teknologi Informasi*, 22(1), 32–44. <https://doi.org/10.12962/j24068535.v22i1.a1208>
- Udu, A. G., Salman, M. T., Ghalati, M. K., Lecchini-Visintini, A., Siddle, D. R., & Dong, H. (2025). Emerging SMOTE and GAN Variants for Data Augmentation in Imbalance Machine Learning Tasks: A Review. *IEEE Access*, 13, 113831–113853. <https://doi.org/10.1109/ACCESS.2025.3584532>
- Yang, Y., Khorshidi, H. A., & Aickelin, U. (2024). A review on over-sampling techniques in classification of multi-class imbalanced datasets: insights for medical problems. *Frontiers in Digital Health*, 6, Artikel 1430245. <https://doi.org/10.3389/fdgth.2024.1430245>
- Yulianto, P. R., & Astuti, Y. P. (2026). Perbandingan Kinerja Algoritma CatBoost, XGBoost, LightGBM dan Random Forest Dalam Memprediksi Risiko Infeksi Aids Dalam Dataset Kesehatan. *Building of Informatics, Technology and Science (BITS)*, 7(4), 2383–2393. <https://doi.org/10.47065/bits.v7i4.8975>
- Zhang, Y., Deng, L., & Wei, B. (2024). Imbalanced Data Classification Based on Improved Random-SMOTE and Feature Standard Deviation. *Mathematics*, 12(11), Artikel 1709. <https://doi.org/10.3390/math12111709>

LAMPIRAN

LINK GITHUB : https://github.com/Xysaa/Kelompok9_Imbalanced